

DEI-FCTUC

APRENDIZAGEM COMPUTACIONAL

(COMPUTAÇÃO ADAPTATIVA)

(COMPUTAÇÃO NEURONAL E SISTEMAS DIFUSOS)

2014-15

Trabalho prático nº 3 – Detecção de crises epiléticas

A epilepsia é uma doença neurológica muito frequente, atingindo cerca de 1% da população (em Portugal cerca de 100 000 pessoas). No atual estado do conhecimento médico cerca de 30% dos epiléticos são intratáveis seja por cirurgia, seja por medicação. Estes estão sujeitos ao aparecimento de uma crise epilética, em qualquer altura, em qualquer lugar, “*like a bolt from the sky*”. Uma crise, que pode demorar alguns segundos ou minutos, afeta seriamente as capacidades motoras, preceptivas, de linguagem, de memória e da consciência, diminuindo seriamente (por não se saber quando aparece) as capacidades profissionais e sociais do paciente.

A possibilidade de deteção de uma crise, com base em informação de sinais cerebrais, principalmente de EEG (ElectroEncefaloGramma), é um tema de investigação atual e um grande desafio científico e tecnológico. Se for possível desenvolver um algoritmo que detete atempadamente uma crise, poder-se-ão desenvolver estratégias para desarmar o desenvolvimento da mesma, evitando assim consequências gravosas.

Um eletroencefalograma é um conjunto de sinais elétricos (Figura 1), na ordem dos microvolts, captados por elétrodos introduzidos por cirurgia na zona focal epilética (Fig. 2b) ou colados à superfície da pele (Fig.2a).

Nos sinais do EEG, resultantes da atividade cerebral (neuronal), está embebida muita informação neurológica. Para detetar uma crise é necessário desenvolver métodos de análise do sinal que sejam capazes detetar padrões do EEG típicos de estados ictais.

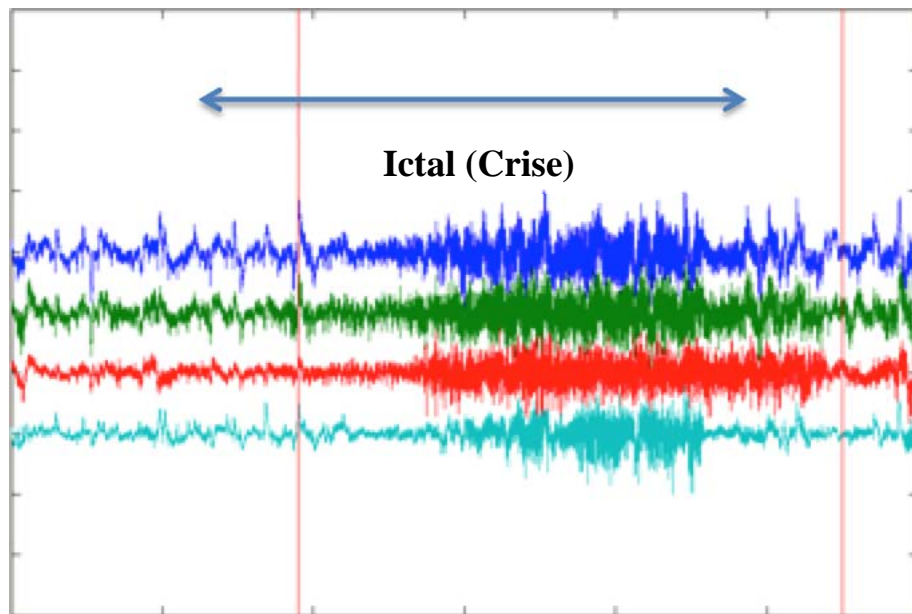


Figura 1. Eletroencefalograma (EEG) com uma crise epilética (vista de 3 canais).




Figura 2. (a) Eléttodos superficiais (não invasivos), (b) Eléttodos intracranianos (invasivos). Cada eléttodo alimenta um canal do EEG, em relação a uma referência.

A detecção de crises trata-se essencialmente de um problema de classificação binário onde se associa cada instante a uma de duas classes, portanto usando uma RN de duas saídas:

- 1-Classe **Não-ictal**, estado normal (saída da RN classificadora 1 0)
- 2- Classe **Ictal**, está a decorrer uma crise (saída da RN classificadora 0 1)

A grande questão está em extrair um bom conjunto de características (*features*) do EEG para essa classificação, que posteriormente serão as entradas dos classificadores. De uma forma genérica temos 2 níveis de processamento: uma fase de extração de características e uma fase de classificação. Neste trabalho já serão fornecidas as características para um canal de EEG invasivo localizado sobre o foco epilético.

As características foram extraídas usando segmentos de EEG de duração de 2s com 50% de sobreposição entre segmentos (isto é, janelas temporais consecutivas partilham metade da informação). Em termos práticos temos em cada segundo um vetor de características que pode ser classificado. No caso em estudo são fornecidas 29 características do espectro de frequência do sinal de EEG, isto é, um vetor de características tem 29 componentes. Em suma, para um registo completo de um paciente temos inúmeros vetores e o objetivo do classificador a desenvolver é detetar os vetores que pertencem ao tempo ictal.

A medida da qualidade do classificador é feita pela sensibilidade (quantas crises verdadeiras detetou) e pela especificidade (quantas falsas crises detetou). Uma grande sensibilidade e uma grande especificidade são os requisitos necessários para o uso clínico.

A sensibilidade é definida por

$$S = \text{Sensibilidade} = \frac{\text{Positivos_verdadeiros}}{\text{Positivos_verdadeiros} + \text{Falsos_negativos}} = \frac{PV}{PV + NF}$$

E a especificidade por

$$E = \text{Especificidade} = \frac{\text{Negativos_verdadeiros}}{\text{Negativos_verdadeiros} + \text{Falsos_positivos}} = \frac{NV}{NV + PF}$$

Para o trabalho em causa são fornecidos características de 11 pacientes gentilmente extraídas e fornecidas pelo Mestre Mojtaba Bandarabadi (agradece-se aqui a sua colaboração na disponibilização destes dados para este trabalho prático).

A cada grupo serão entregues dois ficheiros relativos a dois doentes. São lançados os seguintes desafios:

- i) Construir e treinar uma rede neuronal que tenha o maior sucesso na deteção das crises. Para que uma rede possa detetar as crises tem que ser capaz de identificar a fase ictal logo que ela começa.
- ii) Devem existir crises quer nos dados de treino, quer nos de teste, e nos de validação sempre que possível (pode acontecer que um paciente tenha um número insuficiente de crises para os três conjuntos; neste caso os mais importantes são os de treino e os de teste). Por exemplo para um paciente com 9 crises e considerando 70% das crises para treino deve considerar para treino as primeiras 6 crises e as restantes 3 para teste. A divisão do conjunto de dados em treino, validação e teste tem que ser por isso feita com a indicação dos índices, ver help divideind. Cada um dos conjuntos deve corresponder a dados contíguos no tempo.
- iii) Numa abordagem mais avançada, seleccionar, de entre todas características fornecidas, um subconjunto o mais pequeno possível mas com a máxima capacidade de permitir separar os pontos nas 2 classes.

Cada grupo tem total liberdade de escolha da sua rede neuronal, seja uma arquitetura estudada nas aulas, seja uma outra qualquer (de facto apenas estudamos uma parte das arquiteturas possíveis, que são muitas).

A camada de saída deve ter 2 neurónios, um para cada classe.

Na apresentação dos resultados, no relatório, deve ser especificada em detalhe cada rede usada: número de camadas, neurónios por camada, funções de ativação em cada camada.

Algumas notas:

1 – Escolha da arquitetura .

À partida pode-se usar uma rede feedforward (newfeedforward) normal, com duas ou três camadas. No entanto se pensarmos que o cérebro pode ser encarado como um sistema dinâmico, terá memória, e por isso será interessante estudar a possibilidade de introduzir

atrasos em algumas características, ou em algumas camadas. Pode para isso usar por exemplo a Layer Recurrent Network com

`net=layrecnet(layerDelays,hiddenSizes,trainFcn)` (ver help no Matlab)

que retroenvia a saída de uma camada para a entrada, com um atraso. Podem também usar redes RBF. Estas arquiteturas estão acessíveis no *nntool* bem como algoritmos de treino adequados.

2 -Interface com o utilizador. Para fazer o estudo, pode-se usar o interface *nntool* na linha de comando do Matlab.

A aplicação final a desenvolver por cada grupo deve ter um interface para:

- escolha da rede a treinar e testar
- seleção do conjunto de dados (de treino e de teste, e de validação quando for o caso),
- apresentação dos resultados quer no caso de treino quer no caso de teste, com o resultado do cálculo da sensibilidade e especificidade no próprio interface.

Para construir o interface podem usar o *guide*. O *guide* permite desenvolver rápida e facilmente um interface com o utilizador. Recomenda-se esta alternativa porque permite conhecer esta ferramenta muito útil. Para abrir o *guide* escreve-se na linha de comando `> guide`. Podem estudar o *guide* no manual *online*.

3- Construção dos conjuntos de treino e de teste.

Um aspeto importante nos problemas que envolvem a deteção de eventos raros, como é o caso da deteção de crises, é a curta duração dos eventos face à longa duração sem eventos. No nosso caso uma crise pode durar em média 90 segundos, enquanto o tempo médio de registo para um paciente é de 162 horas. Do ponto de vista da classificação significa que existem muito menos vetores de características correspondentes à classe não-ictal do que correspondentes à classe ictal, o que pode resultar em redes especializadas na classe não-ictal e que por sua vez são incapazes de detetar a classe ictal. Uma forma de contornar este problema é sub-amostrar os dados de treino por forma a considerar um número de vetores da classe não ictal da mesma ordem de grandeza número de vetores da classe ictal. Desta forma sugere-se a escolha aleatória de vetores não-ictais em número igual ao de vetores ictais. De notar que esta operação somente deve ser

implementada no conjunto de treino, enquanto o conjunto de teste (e de validação) deve ficar intacto.

4- Variáveis contidas nos ficheiros de dados:

- FeatVectSel: Matriz de características onde cada coluna representa uma característica extraída e cada linha um vetor de características. Assim tem que se transpor esta matriz para compor a P da notação da aula.
- Trg: Matriz de uma coluna que descreve a classe a que cada vetor de características pertence. O valor “0” significa não ictal, o valor “1” ictal.

5- Pós-processamento:

Numa abordagem inicial, deve classificar ponto a ponto, isto é, cada ponto deve ser associado a uma das 2 classes. Os erros são calculados ponto a ponto.

Numa segunda abordagem podem considerar a seguinte hipótese: só se deteta uma crise se houver por exemplo 10 pontos consecutivos na classe 1 (ictal), ou pelo menos 5 dos últimos 10 são da classe 1. Se houver um pequeno número de pontos da classe 1 isolados, pode-se considerar como não crise, sendo devidos a outros fatores.

Será campeão o grupo que apresentar melhores resultados. Se um grupo quiser testar em mais de dois pacientes, poderá fazê-lo, basta solicitar os dados.

6. Nota sobre as características usadas

O conteúdo em frequências das ondas cerebrais captadas pelo EEG tem sido considerado como fator importante na caracterização do estado cerebral: diferentes estados produzem diferentes espectros, ou seja, a distribuição de energia entre as diferentes bandas do espectro depende do estado cerebral.

O espectro mede a contribuição de cada frequência para o sinal total. A potência espectral de uma banda é dada pela soma das contribuições de potência de cada frequência dentro dessa gama. Admite-se a hipótese de que a distribuição das potências espectrais no estado

ictal é diferente da do estado não-ictal. A classificação só será eficiente se essa hipótese for verdadeira.

Neste estudo usaram-se, por escolha empírica, as potências espectrais normalizadas (de modo a ficarem com média nula e variância unitária) das seguintes 29 bandas de frequência (Hz), incluindo a banda total de 0.5 a 512 Hz:

0.5-3, 3-5, 5-8, 8-10, 10-12, 12-14, 14-16, 16-18, 18-22, 22-26, 26-30, 30-35, 35-40, 40-48, 52-60, 60-70, 70-80, 80-90, 90-98, 102-125, 125-148, 152-175, 175-198, 202-248, 252-298, 302-348, 352-398, 402-512, 0.5-512Hz.

7. Detalhes dos pacientes (da The European Epilepsy Database, construída pelo projeto Europeu FP7 EPILEPSIAE, www.epilepsiae.eu).

ID	Sex	Patient age (y)	Onset age (y)	Localization of seizures	Seizure type	Total EEG Recording (h)	No. of seizure	Seizure duration (s)		
								Mean	Min	Max
107702	F	29	10	RMT, RLT	CP(1), SP(7), UC(1)	183	9	82.3	13	172
109602	F	32	1	LMT	CP(8), UC(1)	162.6	9	121.9	74	157
112502	F	11	3	RMT	CP(4), SP(4), UC(6)	155	14	122.7	56	171
115002	F	32	8	RBF, RMT, LMT	CP(2), SP(2), UC(5)	151.6	9	122.5	38	210
132502	F	18	6	L-T, L-F	CP(13)	127.8	13	86.5	68	105
44202	M	21	5	RLT, RMT	CP(19), UC(3)	170.6	22	131.6	19	199
54802	M	17	1	LMT, LLT, L-T	SP(25), SG(6)	142	31	118.4	33	274
59002	M	18	11	LBT, LLT, RBT	CP(4), SP(4), SG(4), UC(1)	246.2	13	100.2	36	137
63502	F	63	30	LMT, R-T	CP(15), UC(4)	118.9	19	102.8	8	156
92202	M	39	8	L-F, L-C	CP(2), SP(3), UC(25)	110.6	30	15.4	6	43
95802	F	14	13	L-T, LLT	CP(6), SG(4), UC(4)	217.1	14	52.5	7	123
Sum	7F/4M	-	-	-	CP(74), SP(45), SG(14), UC(50)	1785.4	183	-	-	-
Mean	-	26.7	8.7	-	-	162.3	16.6	91.8	32.5	158.8

- ❖ Localization of seizures: ABC; A (R: right, L: left), B (-: none, B: basal, L: lateral, M: mesial), C (F: frontal, T: temporal, C: central). E.g. RMT (right mesial temporal lobe), L-F (left frontal lobe), RBF (right basal frontal lobe).
- ❖ Seizure type: type of the clinical seizures; CP: Complex Partial, SP: Simple Partial, SG: Secondarily Generalized, UC: Unclassified. The numbers given in parentheses represent the number of seizures for each type.
- ❖ Seizure duration: mean, minimum, and maximum values of seizure durations, considering electrographic onsets and offsets of the seizures.

Bom trabalho.
10/10/2014.